

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
УЧРЕЖДЕНИЕ ОБРАЗОВАНИЯ
«БРЕСТСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»
Кафедра интеллектуальных информационных технологий

Отчет по лабораторной работе №1
Специальность системы управления информацией

Выполнил
А. Д. Ребенков,
студент группы АС-68/24
Проверил
А. А. Крощенко,
ст. преп. Кафедры ИИТ,
«__» _____ 2026 г.

Брест 2026

Цель работы: Получить навыки работы с данными в Pandas и Matplotlib/Seaborn.

Освоить очистку, визуализацию и стандартизацию признаков.

Вариант 8

Выборка Pima Indians Diabetes. Содержит медицинские показатели женщин из племени Пима и информацию о наличии у них диабета.

Задачи:

1. Загрузите данные и выведите их статистические характеристики.
2. Проанализируйте столбцы Glucose, BloodPressure, SkinThickness. Нулевые значения в них, скорее всего, являются ошибками. Замените их медианным значением соответствующего столбца.
3. Постройте гистограммы для признаков BMI и Age.
4. Создайте матрицу корреляции только для признаков Glucose, BMI, Age и Outcome.
5. Визуализируйте распределение Outcome (наличие диабета) с помощью круговой диаграммы.
6. Примените стандартизацию ко всем признакам, кроме Outcome.

Код программы:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import os

# Общее задание, загрузка и аналитика

# Получаем путь к папке, где лежит сам файл lab1.py
script_dir = os.path.dirname(os.path.abspath(__file__))
csv_path = os.path.join(script_dir, "pima-indians-diabetes.csv")

# Загрузка данных
df = pd.read_csv(csv_path, comment="#", header=None)
```

```

df.columns = [
    "Pregnancies", "Glucose", "BloodPressure", "SkinThickness",
    "Insulin", "BMI", "DiabetesPedigreeFunction", "Age",
    "Outcome"
]

print("Общая информация о данных (.info()):")
df.info()

print("\nСтатистические характеристики (describe):")
print(df.describe())

print("\nПроверка явных пропусков:")
print(df.isnull().sum())

# 2. Обработка нулей в Glucose, BloodPressure, SkinThickness
cols_to_fix = ["Glucose", "BloodPressure", "SkinThickness"]
for col in cols_to_fix:
    median_val = df[df[col] != 0][col].median()
    df[col] = df[col].replace(0, median_val)

print("\nСтатистика после замены нулей медианой:")
print(df[cols_to_fix].describe())

# Визуализация и обработка

# 3. Гистограммы для BMI и Age
plt.figure(figsize=(10, 4))
plt.subplot(1, 2, 1)
df["BMI"].hist(bins=20, color="skyblue", edgecolor="black")
plt.title("Распределение BMI")

```

```

plt.xlabel("BMI")
plt.ylabel("Количество")

plt.subplot(1, 2, 2)
df["Age"].hist(bins=20, color="orange", edgecolor="black")
plt.title("Распределение Age")
plt.xlabel("Возраст")
plt.ylabel("Количество")
plt.tight_layout()
plt.show()

# 4. Матрица корреляции для Glucose, BMI, Age, Outcome
selected_cols = ["Glucose", "BMI", "Age", "Outcome"]
corr_matrix = df[selected_cols].corr()

print("\nМатрица корреляции:")
print(corr_matrix)

plt.figure(figsize=(6, 5))
sns.heatmap(corr_matrix, annot=True, cmap="coolwarm", fmt=".2f")
plt.title("Матрица корреляции (Glucose, BMI, Age, Outcome)")
plt.show()

# 5. Круговая диаграмма для Outcome
outcome_counts = df["Outcome"].value_counts()
plt.figure(figsize=(6, 6))
plt.pie(
    outcome_counts,
    labels=["Здоровы (0)", "Диабет (1)"],
    autopct="%1.1f%%",
    colors=["#66b3ff", "#ff9999"],

```

```

        startangle=90
    )

plt.title("Распределение признака Outcome")

plt.show()

# 6. Стандартизация всех признаков, кроме Outcome
feature_cols = [col for col in df.columns if col != "Outcome"]

for col in feature_cols:

    df[col] = (df[col] - df[col].mean()) / df[col].std()

print("\nПервые 5 строк после стандартизации:")

print(df.head())

```

Рисунки с результатами работы программы:

```

Общая информация о данных (.info()):
<class 'pandas.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Pregnancies            768 non-null    int64
1   Glucose                768 non-null    int64
2   BloodPressure          768 non-null    int64
3   SkinThickness          768 non-null    int64
4   Insulin                768 non-null    int64
5   BMI                    768 non-null    float64
6   DiabetesPedigreeFunction 768 non-null    float64
7   Age                    768 non-null    int64
8   Outcome                768 non-null    int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB

```

```



Статистические характеристики (describe):

```


	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479	31.992578	0.471876	33.240885	0.348958
std	3.369578	31.972618	19.355807	15.952218	115.244002	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.078000	21.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000	27.300000	0.243750	24.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000	32.000000	0.372500	29.000000	0.000000
75%	6.000000	140.250000	80.000000	32.000000	127.250000	36.600000	0.626250	41.000000	1.000000
max	17.000000	199.000000	122.000000	99.000000	846.000000	67.100000	2.420000	81.000000	1.000000

```
Проверка явных пропусков:
Pregnancies      0
Glucose           0
BloodPressure     0
SkinThickness     0
Insulin           0
BMI               0
DiabetesPedigreeFunction  0
Age               0
Outcome           0
dtype: int64

Статистика после замены нулей медианой:
      Glucose  BloodPressure  SkinThickness
count  768.000000    768.000000    768.000000
mean   121.656250     72.386719     29.108073
std    30.438286     12.096642      8.791221
min     44.000000     24.000000      7.000000
25%    99.750000     64.000000     25.000000
50%   117.000000     72.000000     29.000000
75%   140.250000     80.000000     32.000000
max   199.000000    122.000000    99.000000
```



Распределение признака Outcome



Вывод: Освоены методы первичного анализа данных, замена недопустимых значений, корреляционный анализ, визуализация распределений и нормализация/стандартизация признаков.